LAPORAN ANALISIS BISNIS

Analisis Basis Pelanggan Olist

Analisis sebaran geografis, konsentrasi pasar, dan loyalitas pelanggan marketplace e-commerce Brasil, disertai rekomendasi bisnis dan rancangan dashboard Power BI.

Sumber data: olist_customers_dataset.csv (99.441 baris, 5 kolom)
Disusun: November 2026

Daftar Isi

1. Executive Summary
2. Business Background
3. Problem Statement
4. Business Objectives
5. Dataset Overview
6. Data Quality Assessment
7. Data Cleaning Process
8. Exploratory Data Analysis
9. KPI Analysis
10. Key Business Findings
11. Business Recommendations
12. Power BI Dashboard Overview
13. Limitations
14. Conclusion

1. Executive Summary

Olist punya 96.096 pelanggan unik di 27 negara bagian dan 4.304 kota. Jangkauannya luas, tetapi sebarannya tidak merata. Region Sudeste menyumbang 68,56% pelanggan, dan São Paulo sendiri sudah 41,93%. Kalau dilihat per kota, 41 kota teratas (sekitar 1% dari semua kota) sudah mencakup separuh basis pelanggan.

Temuan yang paling perlu diperhatikan adalah soal loyalitas. Sebanyak 96,88% pelanggan hanya tercatat satu kali. Hanya 2.997 orang, atau 3,12%, yang pernah kembali berbelanja. Artinya, pertumbuhan Olist saat ini hampir seluruhnya bergantung pada pelanggan baru.

Tingkat pembelian ulang juga sedikit berbeda antarwilayah. Nordeste paling rendah (2,52%), sedangkan Sudeste 3,23%. Kota besar juga lebih baik daripada kota kecil, yaitu 3,37% berbanding 2,75%. Kedua selisih ini signifikan secara statistik, tetapi besarnya kurang dari satu poin persentase.

Ada tiga hal yang kami sarankan untuk didahulukan:

1. Program retensi untuk pelanggan yang baru sekali belanja.
2. Pengecekan pengalaman pengiriman di Nordeste sebelum menambah anggaran akuisisi di sana.
3. Melengkapi data transaksi agar dampaknya bisa diukur dalam rupiah, bukan hanya jumlah pelanggan.

2. Business Background

Olist adalah marketplace asal Brasil yang membantu penjual kecil dan menengah berjualan di kanal-kanal marketplace besar. Dataset publiknya berisi sekitar 100 ribu pesanan dari periode 2016 sampai 2018 dan terdiri dari sembilan tabel. Untuk analisis ini, data yang tersedia hanya tabel pelanggan. Gambaran bisnis di atas diambil dari dokumentasi publik dataset, bukan dari isi tabel itu sendiri.

3. Problem Statement

Saat ini belum ada gambaran yang jelas tentang dua hal. Pertama, di mana pelanggan berada dan seberapa besar bisnis bergantung pada wilayah tertentu. Kedua, berapa banyak pelanggan yang kembali berbelanja, dan apakah angkanya berbeda di tiap wilayah. Tanpa jawaban ini, keputusan ekspansi wilayah, penempatan logistik, dan anggaran retensi lebih banyak didasarkan pada intuisi.

4. Business Objectives

1. Memetakan sebaran dan tingkat konsentrasi pelanggan per region, negara bagian, dan kota.
2. Mengukur tingkat pembelian ulang dan mengelompokkan pelanggan berdasarkan frekuensi belanja.
3. Menemukan wilayah yang loyalitasnya di atas atau di bawah rata-rata.
4. Menyiapkan model data dan dashboard Power BI untuk pemantauan rutin.

Pihak yang paling berkepentingan dengan hasil analisis ini:

Stakeholder	Kepentingan
Head of Growth / Marketing	Penentuan wilayah akuisisi dan program retensi
Head of Logistics	Prioritas gudang dan target waktu kirim per wilayah
Tim CRM	Daftar pelanggan loyal dan pelanggan sekali beli
Manajemen	Risiko ketergantungan pada satu pasar dan arah ekspansi

Pertanyaan yang ingin dijawab:

1. Wilayah mana yang menjadi tulang punggung bisnis?
2. Seberapa terkonsentrasi pasar Olist?
3. Berapa persen pelanggan yang kembali berbelanja?
4. Apakah loyalitas berbeda menurut region dan ukuran kota?
5. Wilayah mana yang paling layak dijadikan target berikutnya?

5. Dataset Overview

Kolom	Tipe	Nilai unik	Kegunaan
customer_id	teks, 32 karakter	99.441	ID per pesanan, dipakai untuk join ke tabel orders
customer_unique_id	teks, 32 karakter	96.096	ID orang, dasar perhitungan pembelian ulang
customer_zip_code_prefix	teks, 5 digit	14.994	Lokasi yang lebih detail
customer_city	teks	4.119 nama (4.304 pasangan kota dan negara bagian)	Analisis per kota
customer_state	teks, kode 2 huruf	27	Analisis per negara bagian dan region

Asumsi yang dipakai: setiap customer_id mewakili satu pesanan. Ini sesuai dengan dokumentasi dataset Olist. Karena itu, jumlah customer_id per orang kami gunakan sebagai pendekatan jumlah pesanan. Angka ini tetap perlu dicek ulang jika data pesanan sudah tersedia.

6. Data Quality Assessment

Secara umum datanya bersih. Tidak ada nilai kosong dari 497.205 sel, tidak ada baris ganda, dan tidak ada customer_id yang muncul dua kali. Format ID, kode pos, dan kode negara bagian semuanya valid.

Ada beberapa hal kecil yang tetap perlu ditangani:

Temuan	Jumlah	Penanganan
Kode pos berawalan nol (misalnya 01151)	23.995 baris (24,1%), semuanya di SP	Dibaca sebagai teks agar angka nol di depan tidak hilang
Nama kota yang sama di negara bagian berbeda	163 nama	Analisis memakai gabungan kota dan negara bagian
Ejaan kota berbeda untuk kota yang sama	6 kasus	Disamakan ke ejaan yang paling sering dipakai
Pelanggan dengan lebih dari satu alamat	250 orang, 39 di antaranya pindah negara bagian	Lokasi utama diambil dari alamat yang paling sering dipakai

Kendala utama dataset ini bukan kualitasnya, melainkan cakupannya. Tidak ada informasi harga, produk, maupun tanggal.

7. Data Cleaning Process

Seluruh proses ada di scripts/data_cleaning.py. File mentah tidak diubah, dan hasilnya disimpan terpisah di folder data/processed.

Langkah	Yang dilakukan	Alasan
1	Membaca semua kolom sebagai teks	Menjaga angka nol di depan kode pos
2	Mengecek nilai kosong dan duplikat	Hanya validasi; tidak ada data yang perlu dihapus
3	Merapikan spasi, membuat kode pos menjadi 5 digit, kode negara bagian huruf besar, nama kota huruf kecil tanpa aksen	Supaya formatnya seragam
4	Mengecek format ID, kode pos, dan kode negara bagian	Memastikan tidak ada nilai yang tidak masuk akal
5	Menyamakan 6 ejaan kota, misalnya "mogi-mirim" menjadi "mogi mirim"	Supaya satu kota tidak terhitung dua kali
6	Menambah kolom baru: kunci kota dan negara bagian, nama negara bagian, region, jumlah pesanan per pelanggan, status pelanggan ulang	Kebutuhan analisis dan Power BI
7	Menandai 19 pelanggan dengan 5 pesanan atau lebih (maksimal 17)	Tidak dihapus karena kemungkinan mereka memang pelanggan setia atau reseller
8	Membuat tabel pelanggan (96.096 baris), tabel kota (4.304), dan tabel negara bagian (27)	Untuk model data Power BI
9	Pengecekan akhir: jumlah baris tetap 99.441 dan semua kunci tersambung	Memastikan proses cleaning tidak menimbulkan kesalahan baru

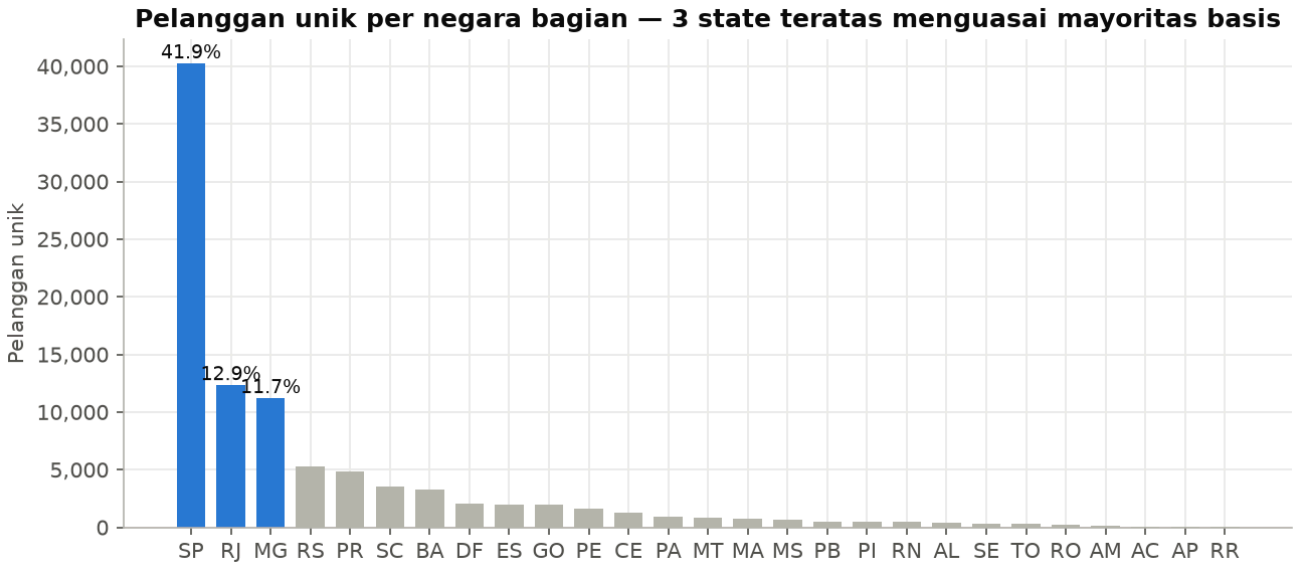
Jumlah baris sebelum dan sesudah cleaning sama, yaitu 99.441. Jumlah kolom bertambah dari 5 menjadi 12. Kolom nama negara bagian dan region tidak ada di data asli. Kolom ini ditambahkan dari pembagian wilayah resmi IBGE.

8. Exploratory Data Analysis

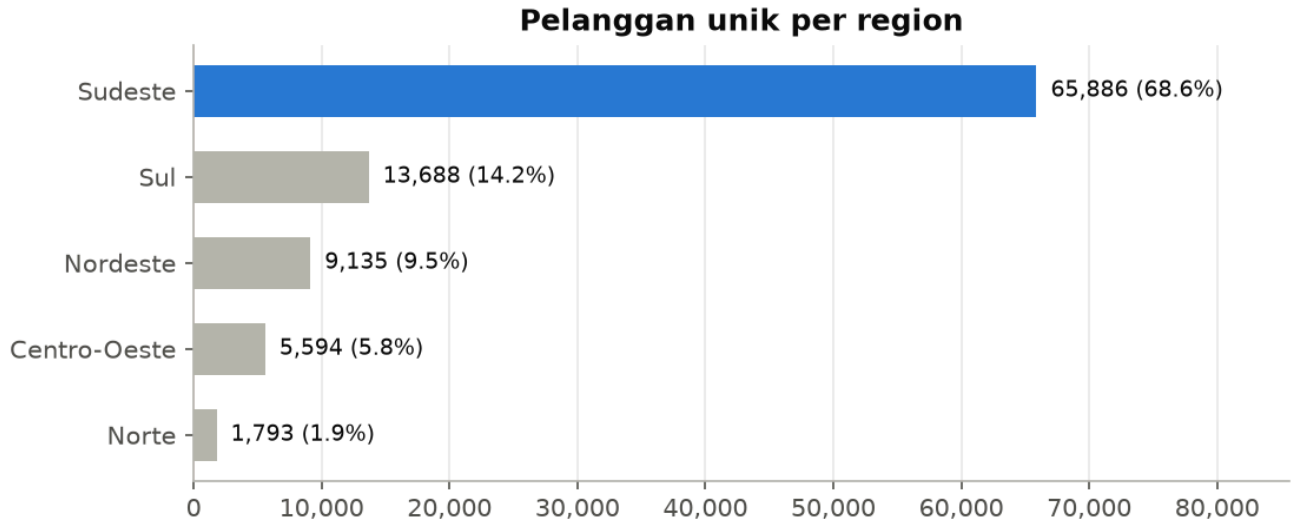
Semua angka di bagian ini berasal dari notebooks/exploratory_data_analysis.ipynb.

8.1 Sebaran pelanggan

São Paulo jauh di depan dengan 40.291 pelanggan, atau 41,93% dari total. Di belakangnya ada Rio de Janeiro (12,88%) dan Minas Gerais (11,71%). Tiga negara bagian ini saja sudah mencakup dua pertiga basis pelanggan. Ketimpangannya juga terlihat dari perbandingan rata-rata dan median: rata-rata pelanggan per negara bagian adalah 3.559, tetapi mediannya hanya 874.



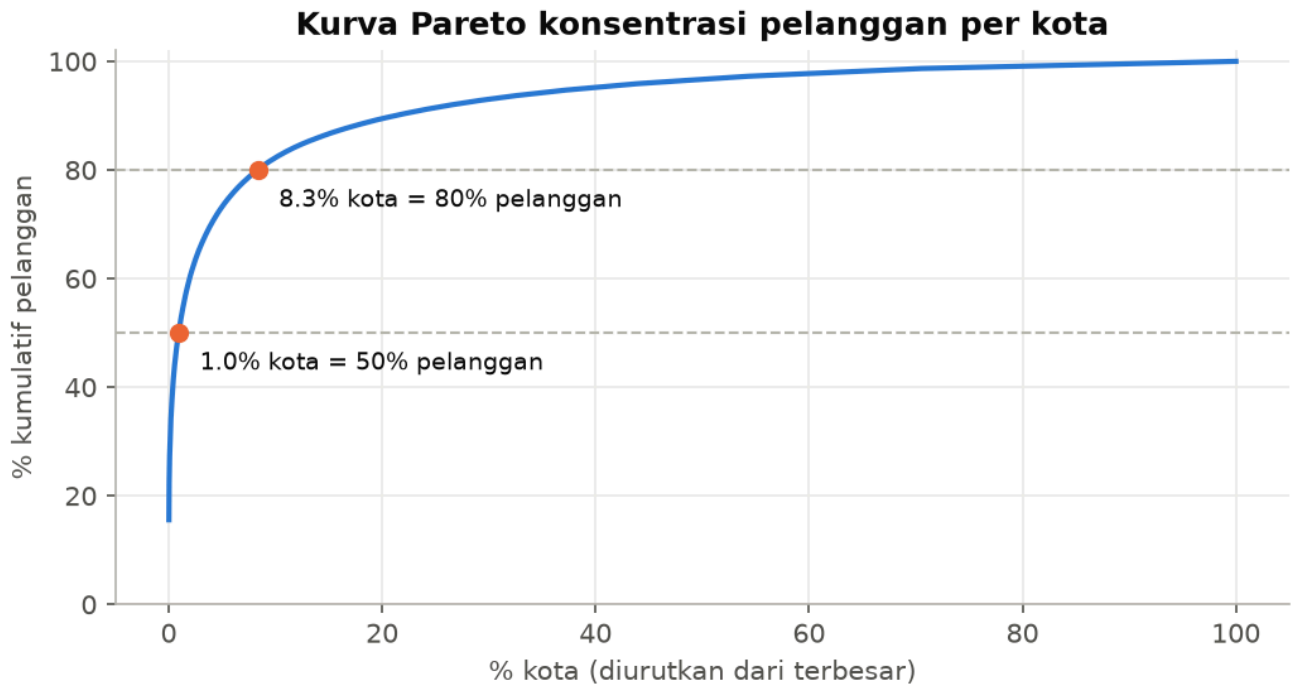
Per region, Sudeste mendominasi dengan 68,56%. Setelah itu Sul 14,24%, Nordeste 9,51%, Centro-Oeste 5,82%, dan Norte hanya 1,87%.



Di level kota polanya sama. Separuh kota hanya punya 3 pelanggan atau kurang, dan 1.290 kota (30%) hanya punya satu pelanggan. Di sisi lain, kota São Paulo sendiri punya 14.984 pelanggan.

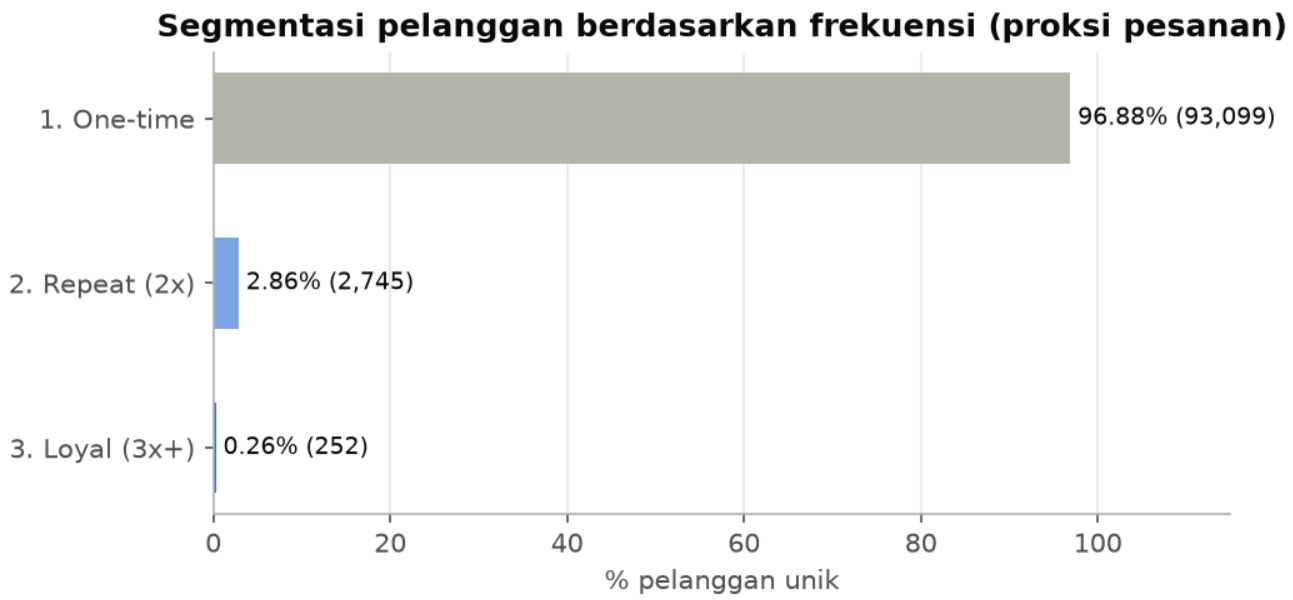


Kurva Pareto di bawah memperjelas hal ini. Sebanyak 1% kota mencakup 50% pelanggan, dan 8,3% kota mencakup 80%. Indeks Gini antarkota sebesar 0,861. Indeks HHI per negara bagian sebesar 2.164, yang masuk kategori konsentrasi sedang dan sudah dekat dengan batas tinggi (2.500).



8.2 Frekuensi belanja

Rata-rata pelanggan hanya tercatat 1,035 kali. Median dan modusnya sama-sama 1. Dari 96.096 pelanggan, 93.099 hanya belanja sekali, 2.745 belanja dua kali, dan hanya 252 yang belanja tiga kali atau lebih. Pelanggan dengan frekuensi tertinggi tercatat 17 kali.

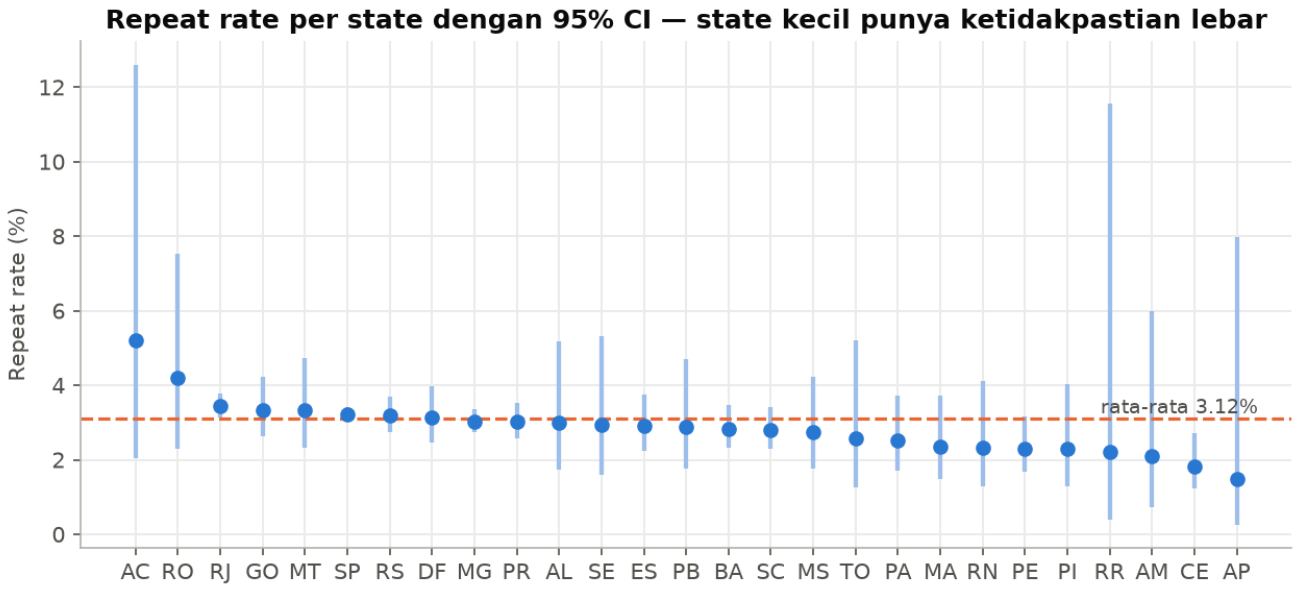


8.3 Loyalitas per wilayah

Region	Pelanggan	Tingkat pembelian ulang
Sudeste	65.886	3,23%
Centro-Oeste	5.594	3,18%
Sul	13.688	3,02%
Norte	1.793	2,79%
Nordeste	9.135	2,52%

Perbedaan antarregion ini signifikan secara statistik (uji chi-square, p = 0,006). Di level negara bagian, Ceará (1,83%) dan Pernambuco (2,30%) paling rendah di antara negara bagian yang punya lebih dari 1.000 pelanggan. Rio de Janeiro paling tinggi di antara negara bagian besar, dengan 3,43%.

Acre (5,19%) dan Rondônia (4,18%) memang terlihat tinggi. Namun jumlah pelanggannya sangat sedikit, hanya 77 dan 239 orang, sehingga angkanya belum bisa dijadikan pegangan. Garis vertikal pada grafik di bawah menunjukkan rentang ketidakpastian untuk setiap negara bagian.



Negara bagian yang pelanggannya lebih banyak cenderung punya tingkat pembelian ulang yang sedikit lebih tinggi. Namun hubungannya lemah (korelasi Spearman 0,385).

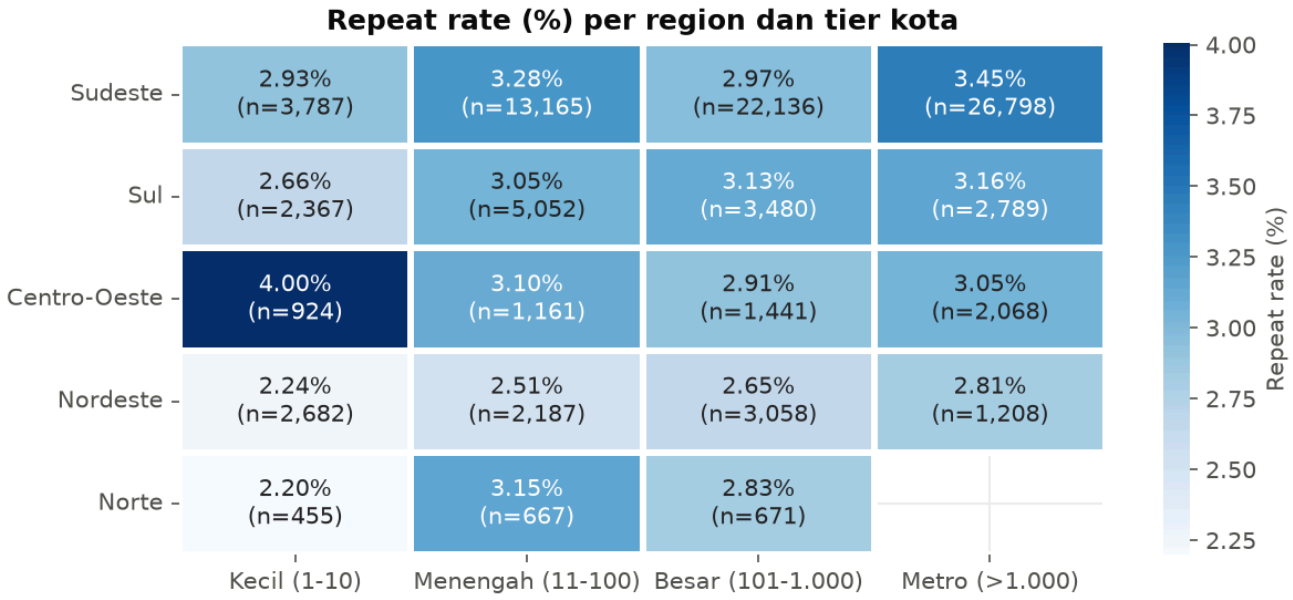
Pola serupa terlihat ketika kota dikelompokkan berdasarkan jumlah pelanggannya:

Ukuran kota	Jumlah kota	Pelanggan	Porsi	Tingkat pembelian ulang
Kecil (1 sampai 10 pelanggan)	3.452	10.215	10,63%	2,75%
Menengah (11 sampai 100)	721	22.232	23,14%	3,14%
Besar (101 sampai 1.000)	122	30.786	32,04%	2,95%
Metro (lebih dari 1.000)	9	32.863	34,20%	3,37%

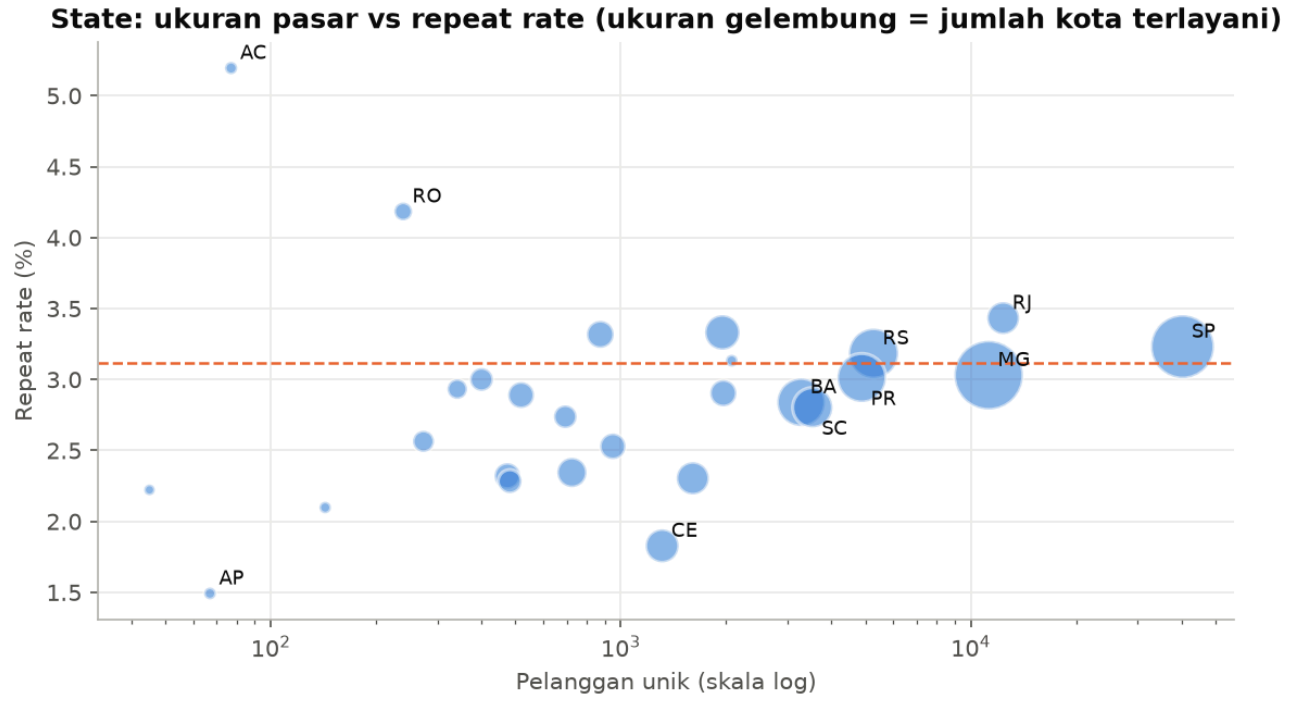
Perbedaan ini juga signifikan secara statistik (p = 0,002).

8.4 Region dan ukuran kota sekaligus

Ketika region dan ukuran kota dilihat bersama, Nordeste konsisten berada di bawah rata-rata nasional untuk semua ukuran kota, yaitu antara 2,24% dan 2,81%. Sel dengan nilai tertinggi yang datanya cukup besar adalah kota metro di Sudeste, dengan 3,45% dari 26.798 pelanggan. Angka 4,00% untuk kota kecil di Centro-Oeste hanya berasal dari 924 pelanggan, jadi perlu dibaca dengan hati-hati.



Pada grafik gelembung di bawah, negara bagian besar seperti SP, RJ, MG, dan RS berada di sekitar atau di atas rata-rata. Sebaliknya, negara bagian di Nordeste dengan jumlah pelanggan menengah, seperti CE, PE, MA, PI, dan RN, berkumpul di bawah garis rata-rata.



8.5 Pelanggan yang berpindah alamat

Dari 2.997 pelanggan yang belanja lebih dari sekali, 250 orang memakai lebih dari satu kode pos. Sebanyak 122 orang tercatat di lebih dari satu kota, dan 39 orang di lebih dari satu negara bagian. Penyebab pastinya belum diketahui. Kemungkinannya antara lain pindah rumah, mengirim barang sebagai hadiah, atau bergantian memakai alamat rumah dan kantor.

9. KPI Analysis

KPI	Cara menghitung	Nilai	Catatan
Pelanggan unik	jumlah customer_unique_id yang berbeda	96.096	Ukuran basis pelanggan
Total pesanan (perkiraan)	jumlah customer_id	99.441	Didasarkan pada asumsi 1 ID = 1 pesanan
Tingkat pembelian ulang	pelanggan dengan lebih dari 1 pesanan dibagi pelanggan unik	3,12%	Sangat rendah
Rata-rata pesanan per pelanggan	total pesanan dibagi pelanggan unik	1,035	Hampir semua hanya sekali beli
Pelanggan loyal	pelanggan dengan 3 pesanan atau lebih	252	Kelompok yang sangat kecil
Porsi 5 negara bagian teratas	pelanggan di 5 negara bagian teratas dibagi total	77,09%	Ketergantungan tinggi
Porsi 10 kota teratas	pelanggan di 10 kota teratas dibagi total	35,13%	Terkumpul di kota besar
HHI negara bagian	jumlah kuadrat porsi tiap negara bagian	2.164	Konsentrasi sedang, mendekati tinggi
Kota yang mencakup 80% pelanggan	analisis Pareto	8,34%	Pasar bertumpu pada sedikit kota
Kota yang terjangkau	jumlah pasangan kota dan negara bagian	4.304	Jangkauan luas tetapi tipis

Rumus yang sama tersedia dalam SQL (sql/business_analysis.sql) dan DAX (powerbi/measures.dax).

10. Key Business Findings

Pelanggan hampir tidak pernah kembali. Dari 100 pelanggan, hanya sekitar 3 yang belanja lagi. Ini berarti biaya untuk mendapatkan pelanggan baru hampir tidak pernah tertutup oleh pembelian berikutnya. Setiap kenaikan satu poin persentase setara dengan sekitar 960 pelanggan tambahan yang kembali berbelanja. Kemungkinan penyebabnya ada beberapa: produk yang dijual memang jarang dibeli ulang, pelanggan tidak sadar bahwa mereka belanja lewat Olist karena transaksinya terjadi di marketplace lain, atau pengalaman pengirimannya kurang baik. Dugaan ini baru bisa dibuktikan dengan data pesanan, produk, dan ulasan.

Bisnis sangat bergantung pada Sudeste, terutama São Paulo. Dua dari tiga pelanggan berada di tiga negara bagian saja. Gangguan di wilayah ini, baik dari sisi logistik, persaingan, maupun ekonomi lokal, akan langsung terasa pada keseluruhan bisnis. Di sisi lain, kepadatan pelanggan ini juga memberi peluang untuk efisiensi

pengiriman. Kami menduga konsentrasi ini sebagian besar mencerminkan jumlah penduduk dan daya beli. Untuk memastikannya, data populasi perlu ditambahkan agar penetrasi per kapita bisa dihitung.

Nordeste tertinggal dalam loyalitas. Tingkat pembelian ulangnya 2,52% dan berada di bawah rata-rata untuk semua ukuran kota. Fortaleza hanya 1,87%, sementara Recife (3,23%) dan Salvador (2,81%) masih cukup baik. Padahal Nordeste punya jumlah kota terbanyak kedua (1.154), meskipun porsi pelanggannya baru 9,51%. Dugaan kami, jarak yang jauh dari pusat penjual di São Paulo membuat waktu kirim lebih lama dan ongkos kirim lebih mahal. Namun ini baru dugaan. Data yang ada hanya menunjukkan adanya pola, bukan penyebabnya.

Kota kecil banyak jumlahnya, tetapi kontribusinya kecil. Ada 3.452 kota kecil, tetapi hanya menyumbang 10,63% pelanggan. Tingkat pembelian ulangnya juga lebih rendah, yaitu 2,75%. Biaya pengiriman ke kota-kota ini kemungkinan lebih mahal per paket.

Data alamat masih perlu dirapikan di sumbernya. Adanya ejaan kota yang berbeda, nama kota yang kembar, dan pelanggan dengan banyak alamat bisa membuat laporan per kota terpecah atau tergabung secara keliru jika tidak ditangani.

Dampak finansial belum bisa diukur. Tanpa data harga, pembayaran, dan tanggal, semua temuan di atas baru bisa dinyatakan dalam jumlah pelanggan, belum dalam nilai uang.

11. Business Recommendations

Rekomendasi	Dasar	Hasil yang diharapkan	Prioritas
Program pembelian kedua: pengingat 7 dan 30 hari setelah belanja, voucher khusus, dan rekomendasi produk terkait. Diuji dulu dengan grup kontrol.	96,88% pelanggan hanya belanja sekali	Tingkat pembelian ulang naik dari 3,1% ke sekitar 4% dalam dua kuartal (target, bukan prediksi)	Dampak tinggi, usaha rendah
Menjaga standar layanan dan waktu kirim di 9 kota metro	9 kota ini menampung 34% pelanggan	Basis utama tetap terjaga	Dampak tinggi, usaha rendah
Menggabungkan tabel orders, payments, items, dan reviews ke dalam analisis	Dampak finansial belum terukur	Temuan bisa dinyatakan dalam nilai uang dan dugaan penyebab bisa diuji	Dampak tinggi, usaha rendah
Memeriksa waktu kirim dan nilai ulasan di Nordeste. Jika memang menjadi masalah, uji subsidi ongkir atau rekrut penjual lokal di Salvador, Fortaleza, dan Recife.	Loyalitas Nordeste paling rendah (2,52%)	Biaya akuisisi di Nordeste lebih cepat kembali	Dampak tinggi, usaha tinggi
Menghitung penetrasi per kapita sebelum memilih wilayah ekspansi	Konsentrasi tinggi di Sudeste, data populasi belum ada	Target ekspansi berdasarkan potensi pasar, bukan hanya jumlah pelanggan saat ini	Dampak tinggi, usaha tinggi
Validasi alamat berdasarkan kode pos dan pilihan kota dari daftar saat checkout	6 ejaan ganda, 163 nama kota kembar	Laporan per kota lebih akurat	Dampak rendah, usaha rendah
Titik ambil barang atau pengiriman gabungan untuk kota kecil	3.452 kota kecil, hanya 10,63% pelanggan	Biaya kirim per paket lebih rendah	Dampak rendah, usaha tinggi

	Usaha rendah	Usaha tinggi
Dampak tinggi	Program pembelian kedua, menjaga kota metro, melengkapi data	Perbaikan di Nordeste, analisis penetrasi per kapita
Dampak rendah	Validasi alamat	Model pengiriman kota kecil

12. Power BI Dashboard Overview

Model datanya memakai star schema dengan satu tabel fakta, yaitu FactCustomerRecord (satu baris per customer_id), dan dua tabel dimensi:

- DimCustomer, dengan satu baris per orang.
- DimGeography, dengan satu baris per kota dan hierarki region, negara bagian, kota.

Dashboard dirancang dalam empat halaman:

1. **Executive Overview:** KPI utama, negara bagian teratas, komposisi pelanggan, dan porsi per region.
2. **Geographic Performance:** peta, kurva Pareto kota, dan tabel yang bisa di-drill dari region sampai ke kota.
3. **Customer Loyalty:** tingkat pembelian ulang per negara bagian dibandingkan rata-rata nasional, heatmap region dan ukuran kota, serta sebaran frekuensi belanja.
4. **City Detail:** halaman drill-through untuk melihat rincian satu kota.

Panduan lengkapnya ada di powerbi/powerbi_guide.md, dengan measure di powerbi/measures.dax dan tema warna di powerbi/olist_theme.json.

13. Limitations

1. Data yang dipakai hanya tabel pelanggan. Pendapatan, profit, nilai pesanan rata-rata, tren waktu, dan konversi tidak bisa dianalisis.
2. Jumlah pesanan per pelanggan masih berupa perkiraan, karena didasarkan pada asumsi 1 customer_id = 1 pesanan.
3. Belum ada data jumlah penduduk. Akibatnya, porsi pelanggan per wilayah lebih mencerminkan besar wilayahnya daripada penetrasi pasarnya.
4. Untuk pelanggan yang berpindah alamat, lokasi utamanya diambil dari alamat yang paling sering dipakai. Aturan ini berpengaruh pada sekitar 0,3% pelanggan.
5. Perbedaan loyalitas antarwilayah memang signifikan secara statistik, tetapi selisihnya kecil (kurang dari 1 poin persentase). Perbedaan ini juga tidak menunjukkan hubungan sebab-akibat.
6. Query SQL dijalankan pada data mentah sebelum ejaan kota disamakan. Karena itu, jumlah kotanya sedikit berbeda: 4.310 di SQL, 4.304 di Python.

14. Conclusion

Jangkauan Olist sudah luas, mencapai lebih dari 4.300 kota. Namun basis pelanggannya bertumpu pada Sudeste, dan hampir semua pelanggan hanya belanja sekali. Karena itu, tantangan terbesarnya saat ini bukan menjangkau wilayah baru, melainkan membuat pelanggan yang sudah ada kembali berbelanja. Langkah berikutnya yang paling berguna adalah menjalankan program retensi sambil melengkapi data transaksi. Dengan begitu, dugaan penyebab rendahnya loyalitas bisa diuji dan hasil programnya bisa diukur dalam nilai uang.